Magnetic Sensor Characterization and Signal Conditioning for Position and Speed Estimation of BLDC Motors

Bearbeiter: Julien Aziz
Betr. Mitarbeiter: Jana Mayer, Ajit Basarur
Referent: Uwe D. Hanebeck

Intelligent Sensor-Actuator-Systems Laboratory (ISAS),
Institute for Anthropomatics and Robotics,
Karlsruhe Institute of Technology (KIT),
Karlsruhe, Germany

Karlsruhe Institute of Technology

http://isas.uka.de

Intelligent Sensor-Actuator-Systems

Gliederung

Motivation

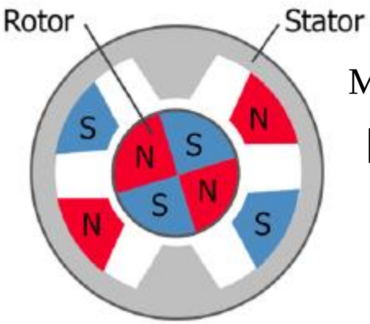

Messung

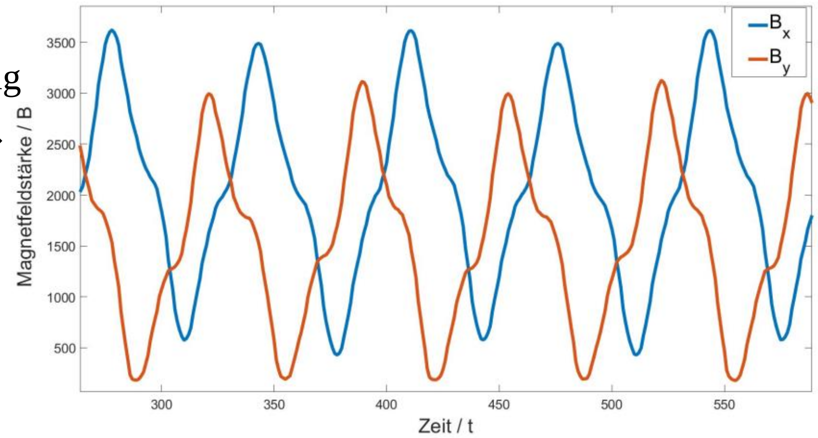

Schätzung

Rotor Position θ
und
Geschwindigkeit ω

- Ziel: Präzise Bestimmung der Rotorposition von BLDC-Motoren anhand des Magnetfelds in Echtzeit

Motivation – Vorherige Arbeiten

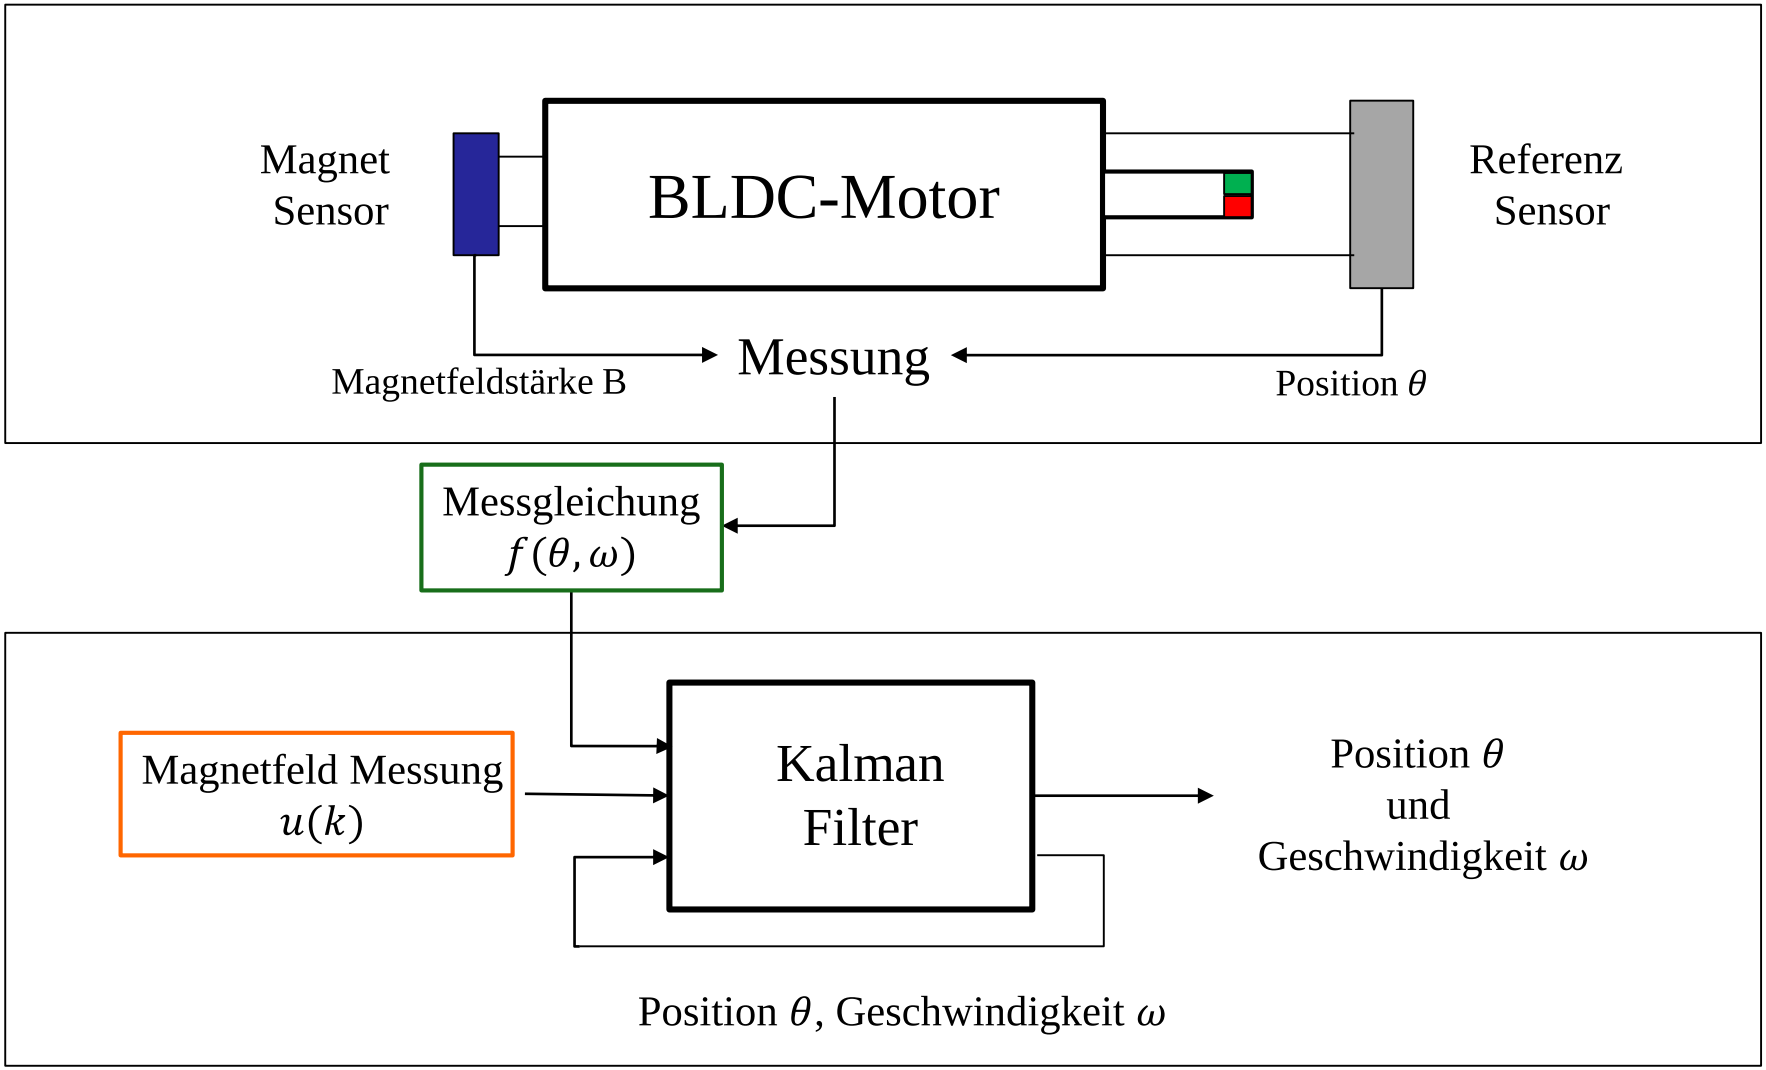

Motivation - Problemstellung

1.

Signalverformung

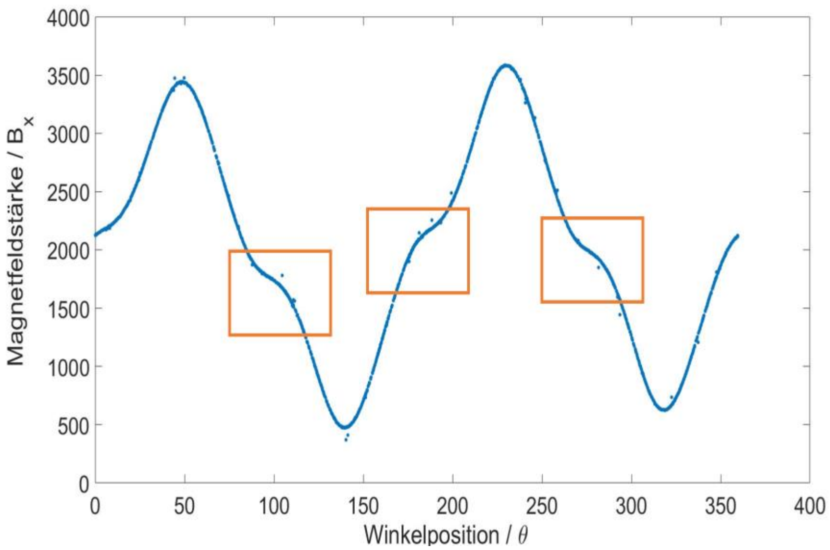

- Erwartung:

  Abbildung: Winkel -> Magnetstärke ist glatte Sinuskurve

- Ist:

  Verformungen an mehreren Punkten

- Ursache:

  Elektromagnetische Induktion in den Motorspulen

Motivation - Problemstellung

2.

Geschwindigkeitsabhängigkeit

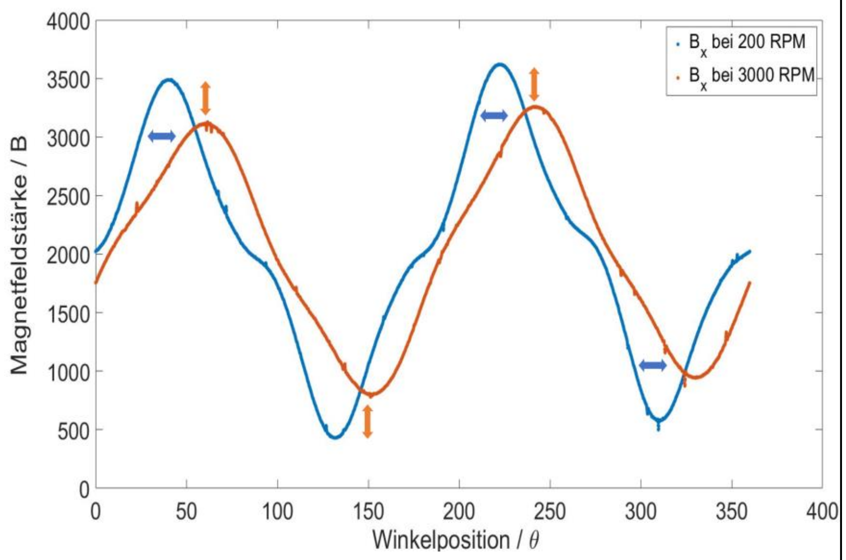

- **Erwartung:**

  Winkelspezifische Magnetfeldstärke für jede Geschwindigkeit gleich

- **Ist:**

  Geschwindigkeitsabhängige Signaltransformation

- **Ursache:**

  Tiefpassfilter des Sensors

Motivation - Problemstellung

1. Verformung

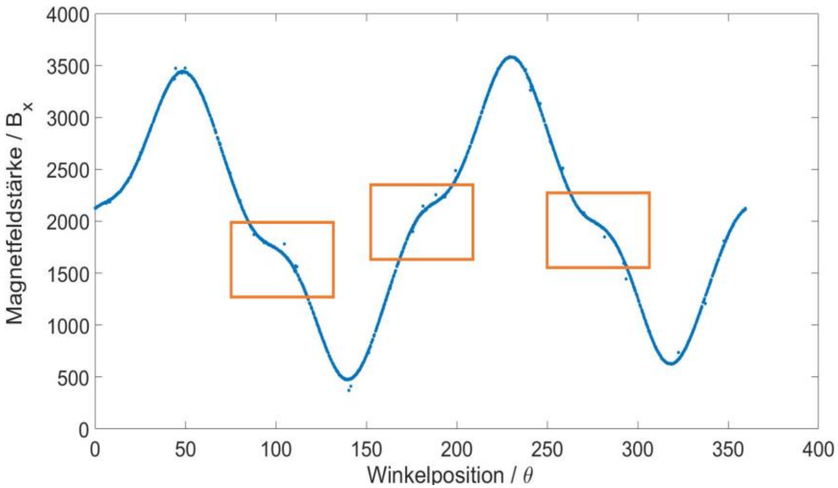

Lösungsansatz:

- Charakterisierung des Magnetflusses
- Neue Sensorposition um ungewollte Einflüsse zu vermeiden

2. Geschwindigkeitsabhängigkeit

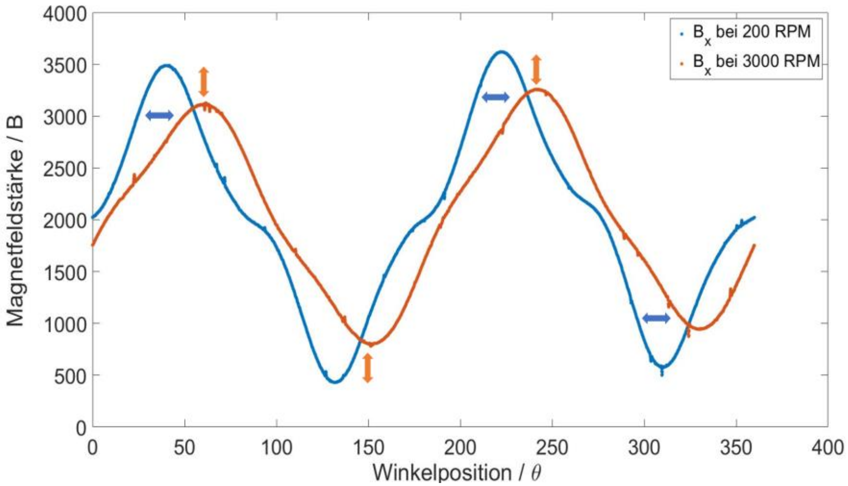

Lösungsansatz:

- Charakterisierung der Sensortransformation
- Approximation des ungefilterten Signals
- Inversion der Sensortransformation

→ Ermöglicht die Verwendung neuer Messgleichungen mit geringer Komplexität

Sensor Position - Magnetfeldmessung

- Ziel: Messung des Magnetfeldes von den rotierenden Permanentmagneten

- Idealfall:

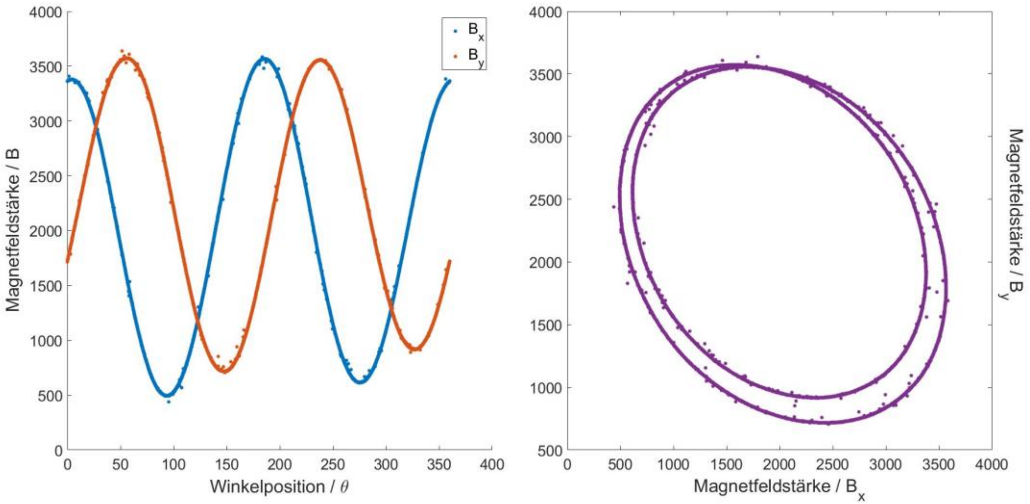

- Problem:
  1. Magnetfeld des Permanentmagneten nicht perfekt symmetrisch
  2. Unerwünschte Störungen durch elektromagnetische Induktion in den Spulen

- Ansatz: Veränderung der Messposition um Störungen zu vermeiden

Sensorposition - Magnetfeldmessung

- Alte Position:

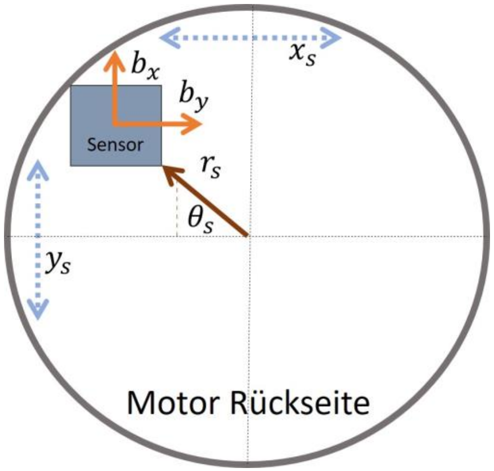

- Messung:

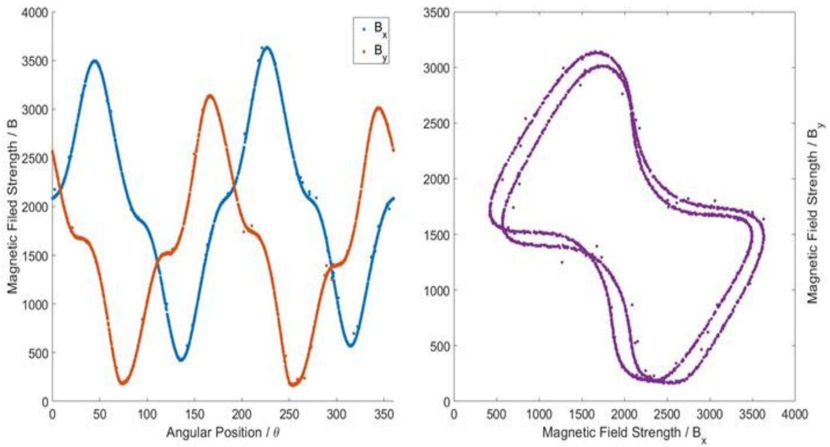

- Positionsänderung
  1. Horizontale Translation entlang x_s
  2. Vertikale Translation entlang y_s
- Berücksichtigung der Spulenverteilung

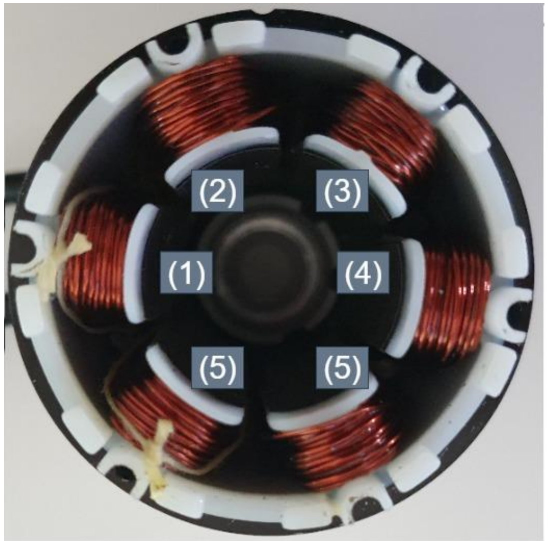

Sensor Position - Translation

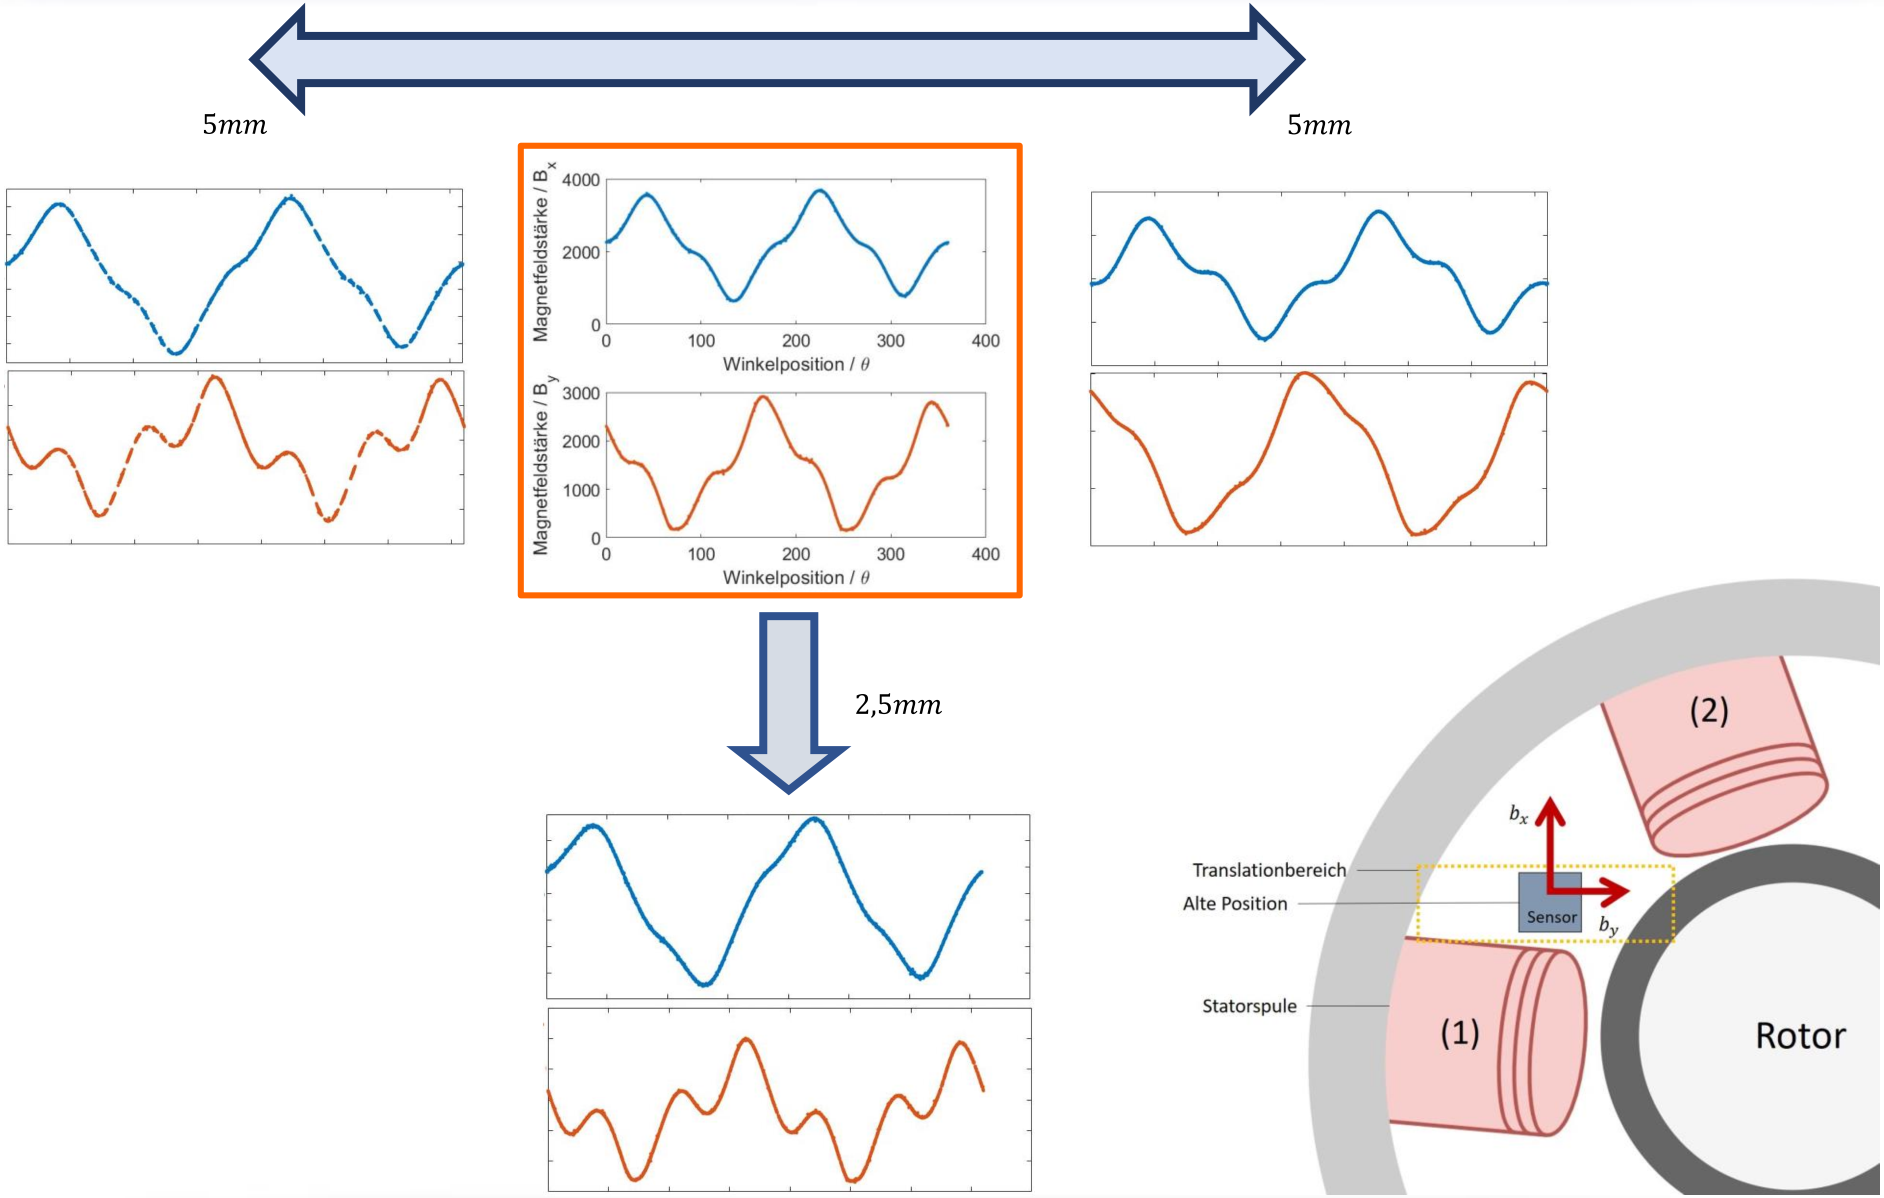

Sensor Position – Exklusive Messrichtung

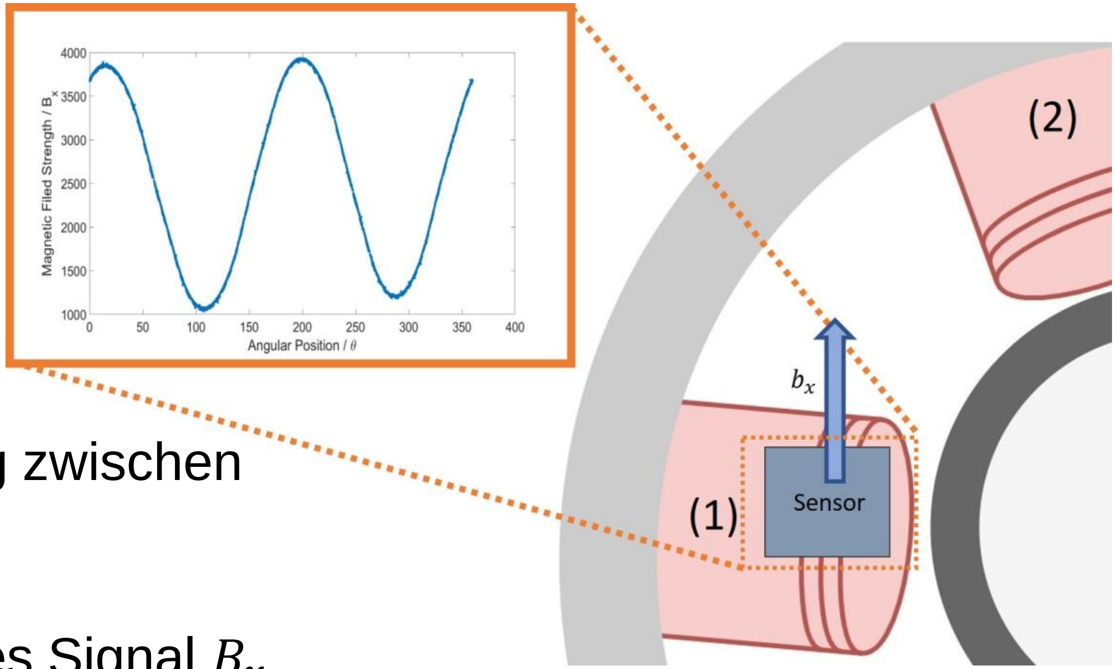

- Vertikale Translation bis Sensor auf Spule (1) liegt
- Fast orthogonale Beziehung zwischen Messrichtung und Spule

➡ Unverformtes sinusoides Signal B_x

- Idee: Nutzung einer exklusiven Messachse b_x für das Schätzmodell
  - ➢ Sensorpositionen mit sinusoidem Signal B_x
  - ➢ Verringerung der Komplexität durch Reduktion der Dimension

Signal Verarbeitung - Approximation

- Problem: Tiefpassfilter verursacht ungewollte Geschwindigkeitsabhängigkeit

Ungefiltertes Signal u_t → Sensorfaltung h → Messung y_t

- Starke Phasenverschiebung und geschwächte Amplitude bei hohen Geschwindigkeiten
- Signale bei niedrigen Geschwindigkeiten nahezu ungefiltert
- Übertragung dieses Verhaltens auf alle Geschwindigkeiten

→ Approximation von Ein-Ausgabe-Paaren

$$(\hat{u}_t, \hat{y}_t)$$

Signal Verarbeitung – Rekonstruktion

- Idee: Transformation der Messung y_t während des Schätzprozesses

- Aktuell:

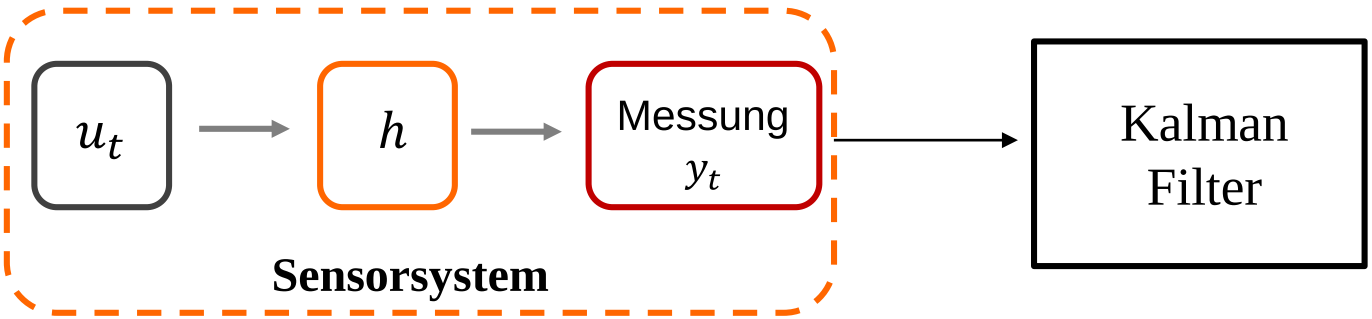

- Identifikation eines neuen Systems g
  - Eingabe ist Messung y_t
  - Ausgabe soll möglichst präzise Schätzung des ungefilterten Signals u_t sein
  - $\hat{u}_t = g * y_t = g * h(u_t)$
  - $\hat{u}_t$ idealerweise Geschwindigkeitsunabhängig

Signal Verarbeitung – Rekonstruktion

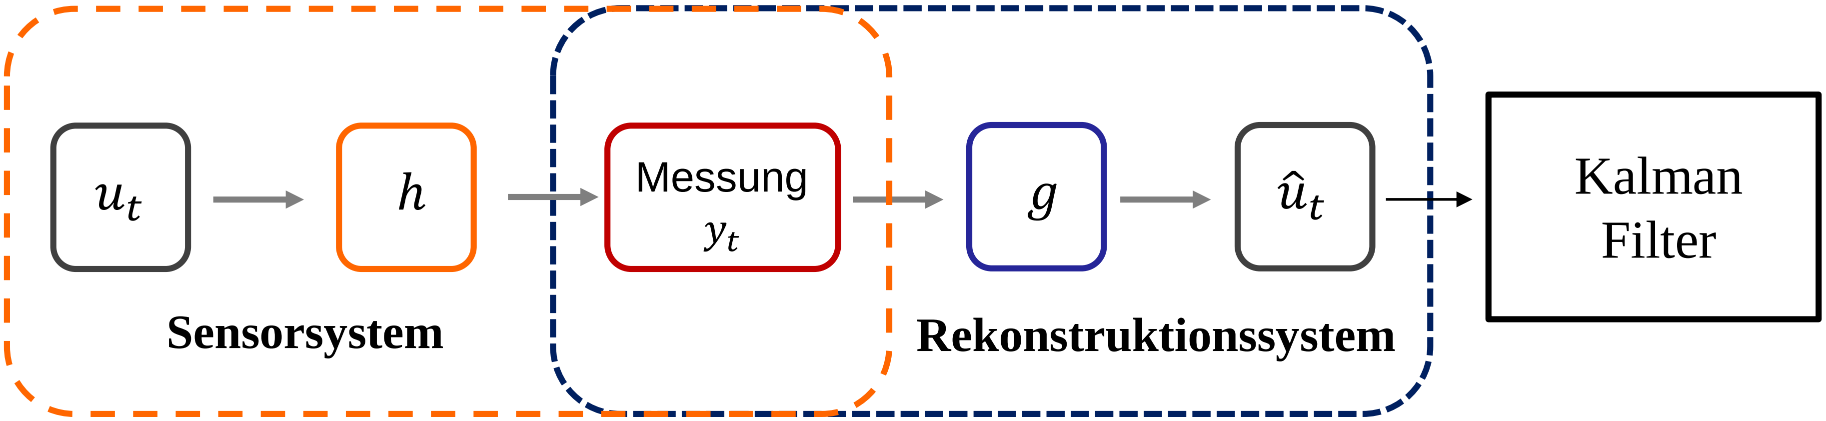

- Identifikation von g mithilfe der approximierten Ein-Ausgabe-Paare $(\hat{u}_t, \hat{y}_t)$
- Evaluation durch Eingabe von echten Messungen y_t

- Idenfikationsansätze:
  1. Korrelationsanalyse
  2. Instrumentvariablen-Schätzung
  3. Sub-Space Identifikation

Signal Rekonstruktion – 1. Korrelationsanalyse

- Beschreibung des Systems durch Impulsantwort $g(k)$

$$y(t) = \sum_{k=0}^{\infty} g(k)\, u(t-k)$$

- Ansatz: Mithilfe der Kreuzkorrelation von Ein- und Ausgabe die Gewichtsfunktion $g(k)$ bestimmen

$$R_{yu}(\tau) = \sum_{k=0}^{\infty} g(k)\, R_{uu}(\tau - k)$$

- Für eine endliche Anzahl an Eingaben *N* wird nun approximiert:
  - $R'_{yu}(\tau) = \frac{1}{N} \sum_{t=1}^{N-\tau} u(t+\tau)\, y(t)$, $\qquad \tau = 0, 1, 2, \ldots N-1$
  - $R'_{uu}(\tau) = \frac{1}{N-\tau} \sum_{t=1}^{N-\tau} u(t+\tau)\, u(t)$, $\qquad \tau = 0, 1, 2, \ldots N-1$

– Pre-Whitening Filter erforderlich

– Verwendete Eingaben müssen das Verhalten des Systems repräsentieren

– Hohe Ordnung und damit hohe Komplexität benötigt

Signal Rekonstruktion – 2. SRIVC Method

- „**S**implified **R**efined **I**nstrumental **V**ariable method for **C**ontinuous-time Systems"
- System beschrieben als Differentialgleichung
  - $y^{(n)}(t) + a_1 y^{(n-1)}(t) + \ldots + a_n y^{(0)}(t) = b_0 u^{(m)}(t) + b_1 u^{(m-1)}(t) + \ldots + b_m u^{(0)}(t)$
  - Sei s der Differentialoperator so lässt sich das System beschreiben:

$$\mathrm{y}(t) = \frac{b_0 s^m + b_1 s^{m-1} + \ldots + b_m}{s^n + a_1 s^{n-1} + \ldots + \mathrm{a_n}} \; u(\mathrm{t})$$

- Idee: $\mathrm{F}(s) = \frac{1}{A(s)} = \frac{1}{s^n + a_1 s^{n-1} + \ldots + \mathrm{a_n}}$ als Filter initialisieren und iterativ das Modell trainieren
- Instrumentvariable: $\boxed{\left[-y_f^{(n-1)}(t) \ldots - y_f^{(0)}(t) \;\; u_f^{(m)}(t) \ldots u_f^{(0)}(t)\right]}$

– $\frac{1}{A(s)}$ muss bekannt sein bzw. geschätzt werden

– Modellordnung muss vorab geschätzt werden

– Kann zu Konvergenzproblemen führen

Signal Rekonstruktion – 3. State Space

- **N4SID** – „Numerical Algorithm for State Space Subspace System Identification"
- System im Zustandraum:
  - $x_{t+1} = Ax_t + Bu_t$
  - $y_t = Cx_t + Du_t$
- Idee: Ordnung n und Parametrisierung des Systems aus Unterräumen von Ein/Ausgabe schätzen
- Hankel-Matrizen vergangener/zukünftiger Ein/Ausgaben
  - U_p, U_f, Y_p, U_f
- $O_i = Y_{f/U_f} \left(U_p\ Y_p\right)^T$
  - Schiefe Projektion der Zukunfts-Ausgabe Y_f entlang des Zeilenraums der Zukunftseingabe U_f in den Zeilenraum der vergangenen Ein/Ausgaben U_p, Y_p
- Aus Singulärwertzerlegung von O_i kann nun:
  - Systemordnung n bestimmt werden
  - Basis für Regression der Parametrisierung definiert werden

Schätzmodell

- Kombination 3 neuer Ansätze
  1. Eindimensionale Messvariable B_x
  2. Neue Sensorposition mit glattem sinusoidem Signal
  3. Transformation des gemessenen Signals vor Eingabe in den Kalman Filter mit identifiziertem System g

➡ Signifikante Vereinfachung der Messgleichung f

- Eindimensionale Abbildung
- Geschwindigkeitsunabhängig
- Beschreibbar als einfacher sinusoider Term

Messgleichung

$$f: Rotorwinkel \rightarrow Magnetfeldstärke$$
$$\theta \rightarrow B_x$$

Schätzmodell - Training

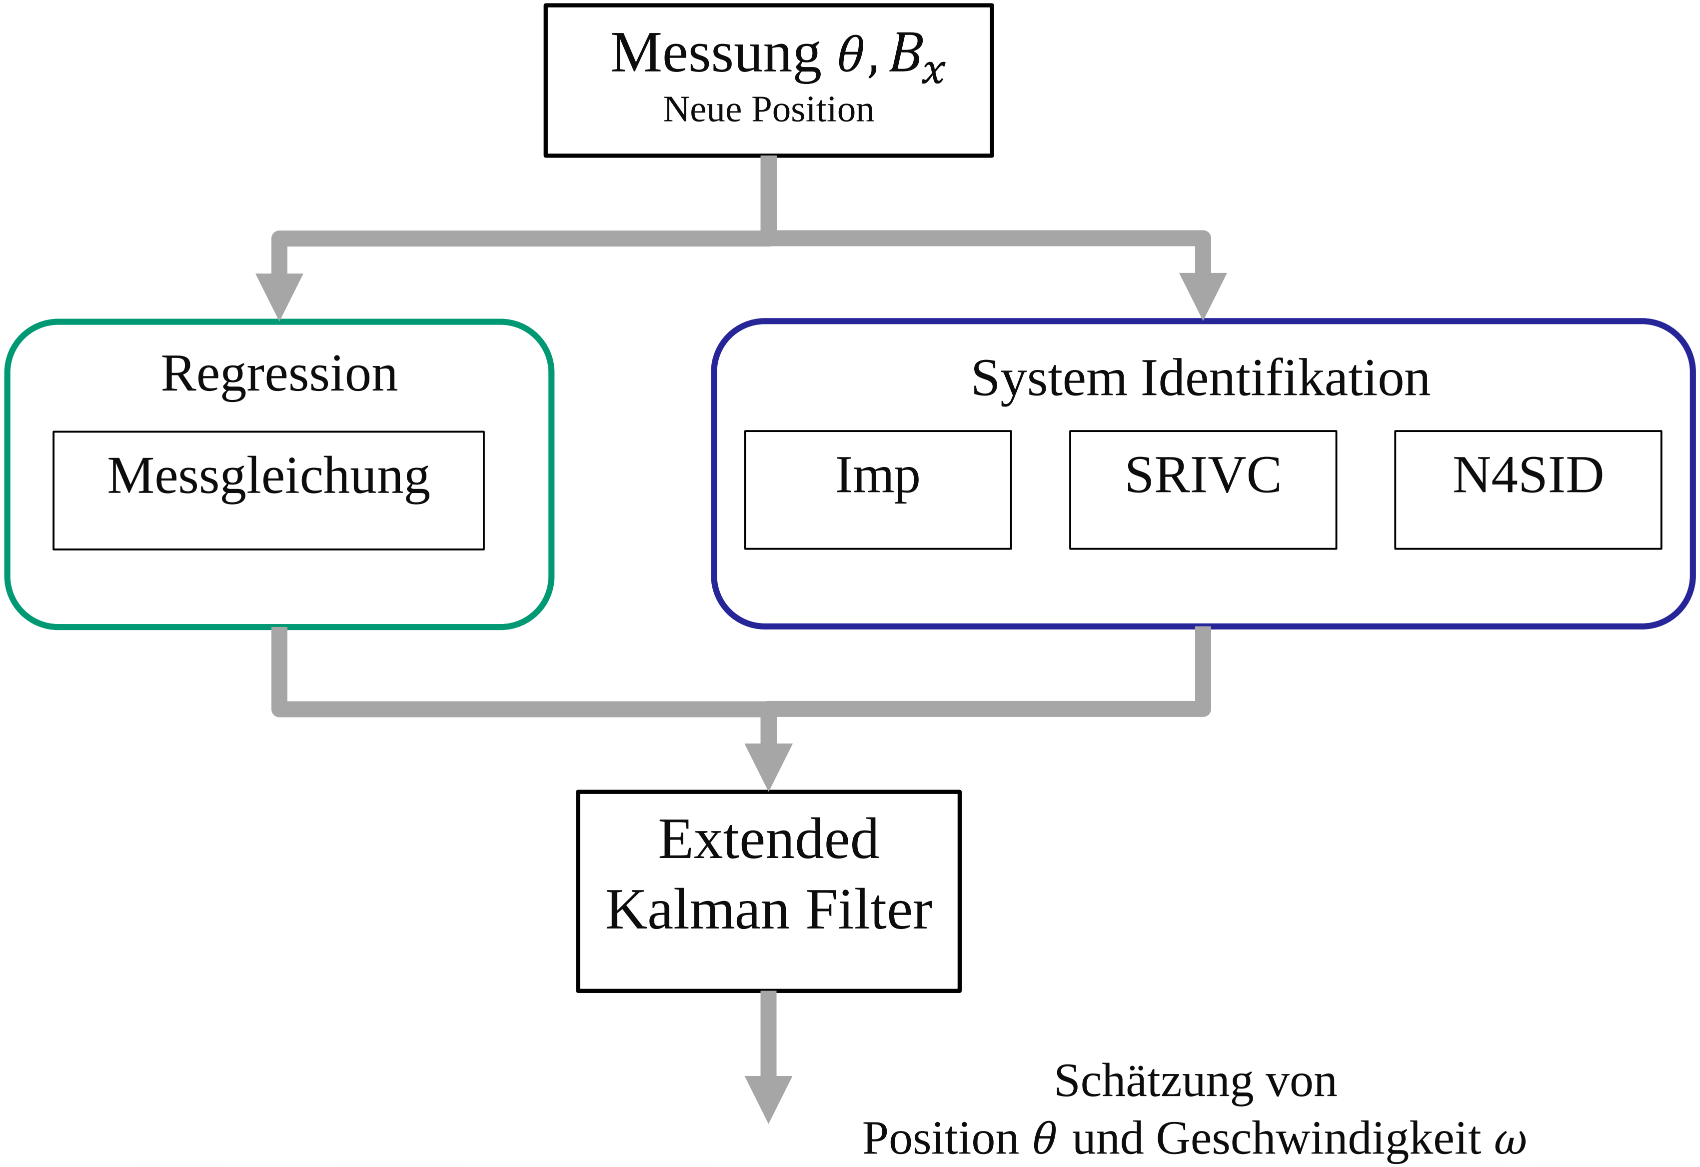

Auswertung – Position Schätzfehler

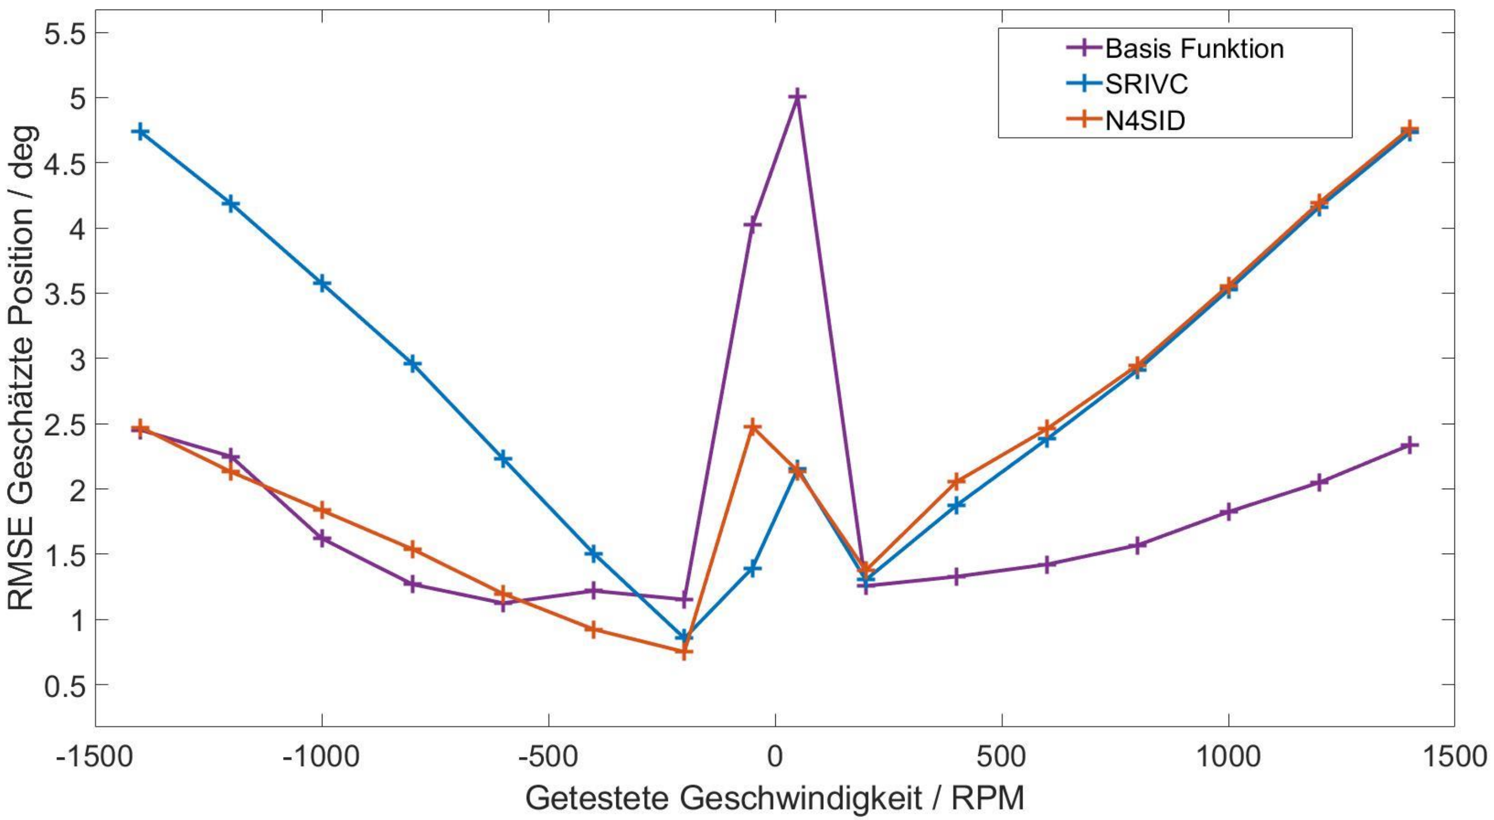

- Basisfunktion sensibel gegenüber Rauschen
- SRIVC steigender Fehler bei hohen Geschwindigkeiten
- N4SID starke Abweichung zwischen Rotationsrichtungen

Auswertung – Geschw. Schätzfehler

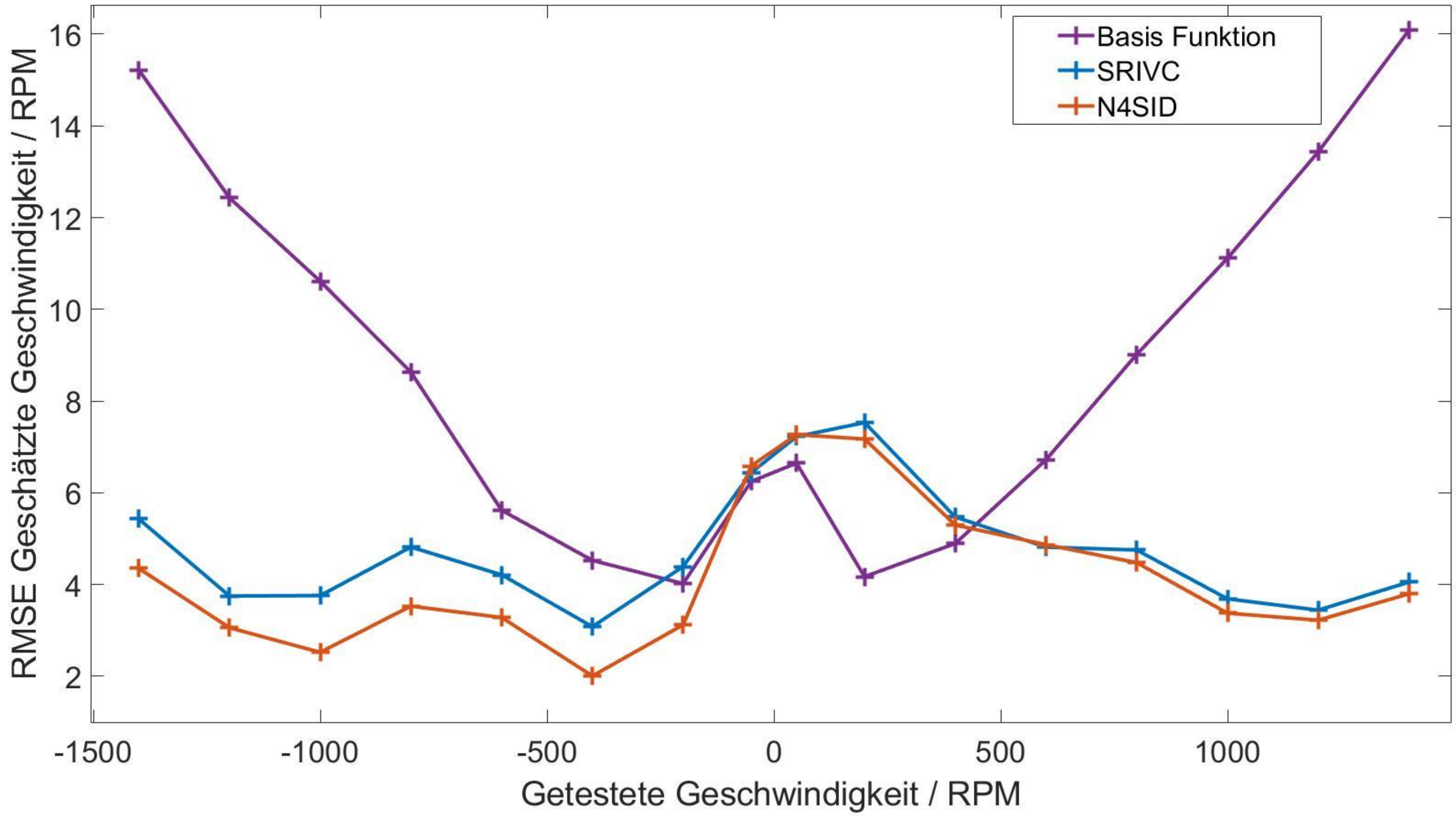

- Basisfunktion hat Probleme bei steigenden Geschwindigkeiten
- SRIVC und N4SID relativ konstant über alle Geschwindigkeiten
- Leicht erhöhte Fehler bei niedrigen Geschwindigkeiten

Auswertung – Rechenzeit

- Komplexität der System bestimmt durch Modellordnung

		Imp	SRIVC	N4SID
Modellordnung	**Positiv**	15	3	3
	Negativ	11	2	2

- Rechenzeit pro Schätziteration als Indikator für Komplexität des Schätzmodells

	Imp	SRIVC	N4SID	Basis Funktion
Rechenzeit pro Schätzung / ms	0.0689	0.0679	0.0662	0.3229

- Signifikante Reduzierung der Rechenzeit zu vorherigen Arbeiten
- Komplexität der Systeme wenig Einfluss auf Rechenzeit

Fazit

- Zwei wesentliche Probleme des Schätzmodells eliminiert
  - Neue Sensorposition mit unverformten Signal der Permanentmagneten
  - Effiziente System konstruiert um ungewollte Tiefpasstransformationen zu invertieren
- Erfolgreich die Dimension der Messvariable reduziert
- Integrierung der neuen Ansätze in das Modell mit präzisen Schätzergebnissen
  - $RMSE(\theta)_{N4SID} = 2{,}3168\ deg$
  - $RMSE(\omega)_{N4SID} = 4{,}2435\ RPM$
- Signifikante Rechenzeitreduktion von $0{,}2567\ ms$ zu vorherigen Arbeiten bei gesteigerter Schätzpräzision

Ausblick

- Rotation des Sensors ermöglichen für besser Messpositionen
- Erhöhung der Systemkomplexitäten für präzisere Ergebnisse und weniger Overhead
- Das Schätzmodell unter Last evaluieren

Thank you for your attention

Intelligent Sensor-Actuator-Systems

Ein-Ausgabe-Simulation

- $f: Rotorwinkel \rightarrow Magnetfeldstärke$ individuell für jede Geschwindikeit
- Abbildung einer niedrigen Geschwindigkeit als Referenz

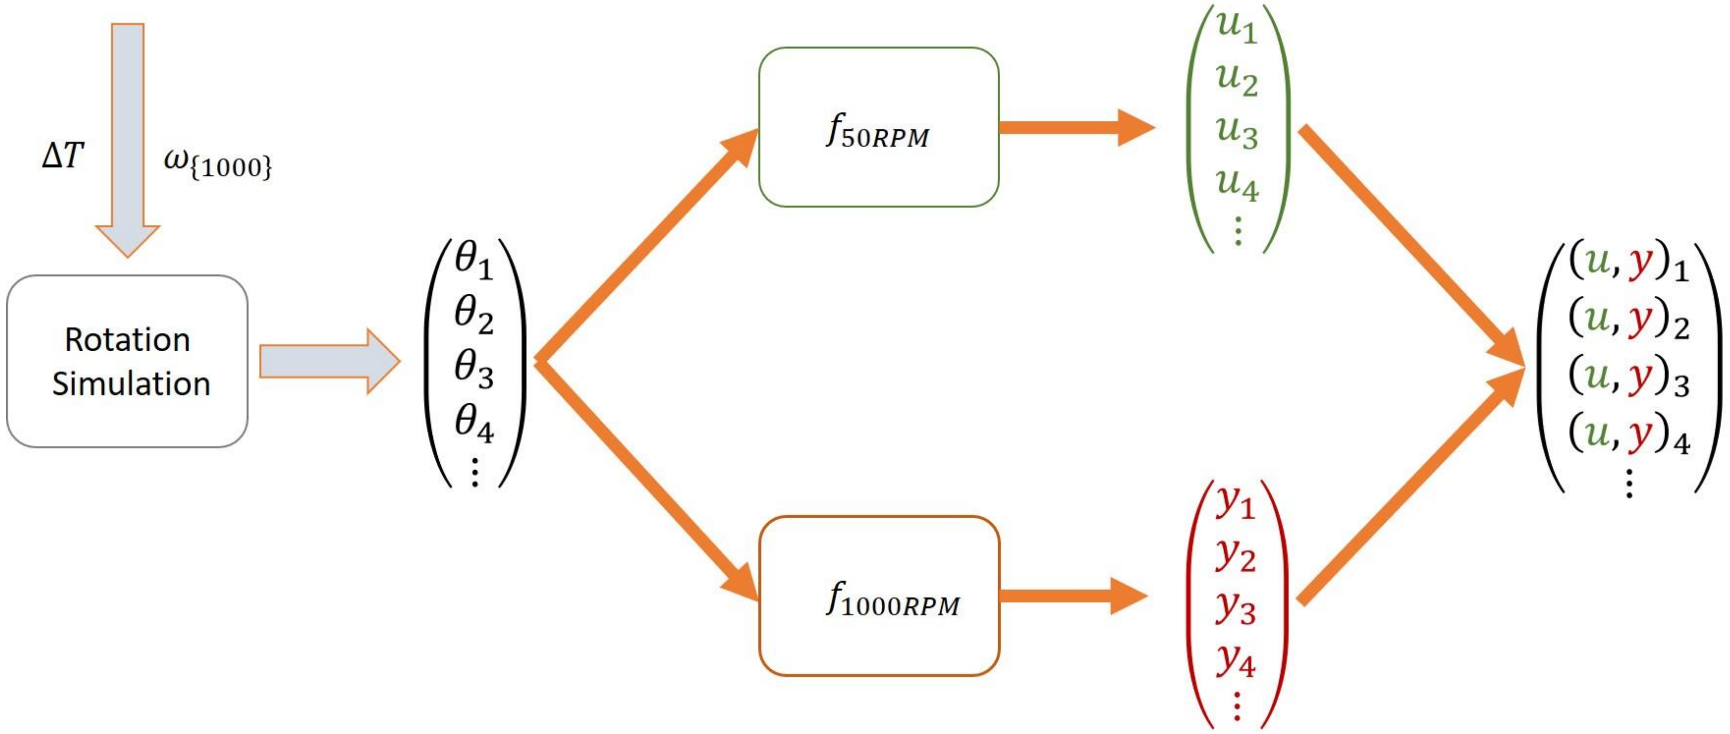

Signal Rekonstruktion – 1. Korrelationsanalyse

- Für eine endliche Anzahl an Eingaben *N* wird nun approximiert:
  - $R'_{yu}(\tau) = \frac{1}{N} \sum_{t=1}^{N-\tau} u(t + \tau)\, y(t)$, $\qquad \tau = 0, 1, 2, \dots N-1$
  - $R'_{uu}(\tau) = \frac{1}{N-\tau} \sum_{t=1}^{N-\tau} u(t + \tau)\, u(t)$, $\qquad \tau = 0, 1, 2, \dots N-1$

- Mit folgendem Gleichungssystem:
  - $\begin{pmatrix} R'_{yu}(0) \\ \vdots \\ R'_{yu}(N-1) \end{pmatrix} = \begin{pmatrix} R'_{uu}(0) & \cdots & R'_{uu}(N-1) \\ \vdots & \ddots & \vdots \\ R'_{uu}(N-1) & \cdots & R'_{uu}(0) \end{pmatrix} \begin{pmatrix} g(0) \\ \vdots \\ g(N-1) \end{pmatrix}$

  lässt sich ein $g(t)$, N-ter Ordnung ermitteln

Signal Rekonstruktion – 2. SRIVC Method

- „**S**implified **R**efined **I**nstrumental **V**ariable method for **C**ontinuous-time Systems“
- System beschrieben als Differentialgleichung
  - $y^{(n)}(t) + a_1 y^{(n-1)}(t) + \ldots + a_n y^{(0)}(t) = b_0 u^{(m)}(t) + b_1 u^{(m-1)}(t) + \ldots + b_m u^{(0)}(t)$
  - Sei s der Differentialoperator so lässt sich das System beschreiben:

$$\mathrm{y}(t) = \frac{B(s)}{A(s)} \mathrm{u(t)}$$

mit $A(s) = s^n + a_1 s^{n-1} + \ldots + \mathrm{a_n}$

$B(s) = b_0 s^m + b_1 s^{m-1} + \ldots + b_m$

- Fehlerfunktion: $\varepsilon(t) = y(t) - \frac{B(s)}{A(s)} u(t)$
- Umgeformt: $\varepsilon(t) = \frac{1}{A(s)} [A(s)y(t) - B(s)u(t)]$
- Idee: $\mathrm{F}(s) = \frac{1}{A(s)}$ als Filter initialisieren und iterativ das Modell trainieren

Signal Rekonstruktion – 2. SRIVC Method

- Fehlerfunktion: $\varepsilon(t) = F\,[A(s)y(t) - B(s)u(t)]$
- Da Linear: $\varepsilon(t) = A(s)\,y_f(t) - B(s)u_f(t)$
  - Bzw. $\varepsilon(t) = y_f^{(n)}(t) + \ \dots + \ a_n y^{(0)}(t) \ - b_0 u_f^{(m)}(t) - \ \dots - b_m u^{(0)}(t)$
  - Wobei $y_f^{(i)} = f_i(t) \ * y(t) \qquad , i = 0, \dots, n$
  - Mit $f_i(t) = L^{-1}(\frac{s^i}{A(s)})$

➢ $y_f^{(n)}(t) = \left[-y_f^{(n-1)}(t) \dots - y_f^{(0)}(t) \ \ u_f^{m}(t) \dots u_f^{0}(t)\right] \begin{bmatrix} a_1 \\ \dots \\ a_n \\ b_0 \\ \dots \\ b_m \end{bmatrix} + \varepsilon(t)$

- Instrumentvariable: $\boxed{\left[-y_f^{(n-1)}(t) \dots - y_f^{(0)}(t) \ \ u_f^{(m)}(t) \dots u_f^{(0)}(t)\right]}$

– $\frac{1}{A(s)}$ muss bekannt sein bzw. geschätzt werden

– Modellordnung muss vorab geschätzt werden

– Kann zu Konvergenzproblemen führen

Signal Rekonstruktion – 3. State Space

- **N4SID** – „Numerical Algorithm for State Space Subspace System Identification"
- System im Zustandsraum:
  - $x_{k+1} = A\,x_k + B\,u_k$
  - $y_k = C\,x_k + D\,u_k$
- Idee: Ordnung n und Parametrisierung des Systems aus Unterräumen von Ein/Ausgabe schätzen
- Sei:
  - $X_p = (x_{0,}\ \dots, x_{j-1})\epsilon R^{n\times j}$ Zustandssequenz der Vergangenheit
  - $X_f = (x_i, \dots, x_{i+j-1})\epsilon R^{n\times j}$ Zustandssequenz der Zukunft
  - $U_p = \begin{pmatrix} u_0 & \cdots & u_{j-1} \\ \vdots & \ddots & \vdots \\ u_{i-1} & \cdots & u_{i+j-2} \end{pmatrix}$ die Hankel-Matrix vergangener Eingaben
  - $U_f = \begin{pmatrix} u_i & \cdots & u_{2i+j-1} \\ \vdots & \ddots & \vdots \\ u_{2i-1} & \cdots & u_{2i+j-2} \end{pmatrix}$ die Hankel−Matrix der zukünftigen Eingaben
  - Für Ausgaben Y_p, Y_f analog

Signal Rekonstruktion – 3. State Space

- Erweiterte Beobachtungsmatrix:

  $\Gamma_i = \begin{pmatrix} C & CA & CA^2 \ldots & CA^{i-1} \end{pmatrix}^T$

- $O_i = Y_{f/U_f} \begin{pmatrix} U_p \; Y_p \end{pmatrix}^T$
  - Schiefe Projektion der Zukunfts-Ausgabe Y_f entlang des Zeilenraums der Zukunftseingabe U_f in den Zeilenraum der vergangenen Ein/Ausgaben U_p, Y_p
  - Wobei gilt: $O_i = \Gamma_i \mathrm{X_f}$

- Aus Singulärwertzerlegung von O_i kann nun:
  - Systemordnung n bestimmt werden
  - Die erweiterte Beobachtungsmatrix Γ_i geschätzt werden

- Mit bekannten $\Gamma_i, \mathrm{O_i}$ können nun X_f sowie A und C bestimmt werden
- B, D durch lineares Regressionsverfahren

Auswertung - Schätzfehler

Positive Rotation

System	RMSE(θ) / deg	RMSE(ω) / RPM
Imp	121.1584	49.6462
SRIVC	2.8800	5.1206
N4SID	2.9678	4.9448

Negative Rotation

System	RMSE(θ) / deg	RMSE(ω) / RPM
Imp	120.2361	52.7653
SRIVC	2.6809	3.5901
N4SID	1.6657	3.5546